

Actividad practica aplicada

Etapas de Transferencia

Daniel Alfonso Rozo Briceño

Fundación universitaria comenzar

Ciencia de datos, programación para ciencia de datos II

Docente, William Eduardo Clavijo Bohorquez

septiembre 2026

Lista de figuras y tablas

Figura 1. Vista principal de la aplicación Dash con filtros, indicadores y distribuciones.

Tabla 1. Variables y uso analítico.

Tabla 2. Comparación de modelos de regresión.

Tabla 3. Experimentos de regresión logística.

Tabla 4. Archivos de reproducibilidad y publicación.

Introducción

El proyecto consolida el proceso desarrollado en las actividades anteriores sobre la relación entre las horas semanales de estudio y el puntaje obtenido en un examen. La muestra contiene 100 observaciones simuladas y fue construida con una semilla fija para conservar la reproducibilidad. El análisis preliminar mostró una asociación positiva fuerte entre ambas variables, lo cual justificó avanzar desde la exploración descriptiva hacia el contraste de hipótesis, la predicción continua y la clasificación de la condición de aprobación.

La solución final adopta un enfoque de producto analítico. Además de evaluar y mejorar los modelos, transforma los resultados en un dashboard interactivo completamente en español. La aplicación fue construida con Dash, framework de Python para aplicaciones de datos, e integra gráficos de Plotly, procesamiento con Pandas y estimación con SciPy y scikit-learn. Los controles permiten cambiar rangos y umbrales sin modificar el código, mientras que las función reactiva (callback) recalculan métricas y visualizaciones.

Pregunta de investigación

¿En qué medida las horas semanales de estudio se relacionan con el puntaje del examen y qué tan útil es esta variable para predecir el desempeño académico y la condición de aprobación?

Justificación

Un reporte estático permite documentar resultados, pero limita la exploración de escenarios. El dashboard amplía el análisis al ofrecer filtros, comparación de modelos y modificación del umbral de clasificación. Esta característica es relevante porque métricas como sensibilidad y especificidad cambian según la decisión operativa. La interfaz hace visible dicho intercambio y evita presentar una única cifra como si fuera suficiente para evaluar el modelo.

Objetivos

Objetivo general

Desarrollar y documentar un dashboard interactivo que permita evaluar, comparar y comunicar modelos estadísticos aplicados al rendimiento académico, manteniendo un flujo reproducible desde los datos hasta la publicación en GitHub y Binder.

Objetivos específicos

- Evaluar la relación entre las horas de estudio y el puntaje mediante correlación, contraste de hipótesis y regresión.
- Comparar una regresión lineal simple, una especificación polinómica de grado tres y una variante regularizada con Ridge.
- Entrenar modelos de regresión logística y experimentar de forma controlada con los valores de C y los solvers liblinear y lbfgs.
- Implementar filtros dinámicos, histogramas, dispersión con tendencia, diagnóstico de residuos, curva logística y matriz de confusión.
- Documentar las limitaciones de los datos simulados y proponer variables y validaciones para una etapa posterior.
- Preparar los archivos necesarios para ejecutar el proyecto en Anaconda, publicarlo en GitHub y abrirlo en Binder.

1. Datos y preparación

La base contiene las variables originales Horas_Estudio_Semana y Puntaje_Examen. La variable binaria Aprobado se construyó con un umbral de 70 puntos. Para la comparación de regresiones se añadieron términos cuadrático y cúbico de las horas. Estos términos permiten representar curvatura, pero no deben interpretarse como nuevas mediciones independientes.

Variable	Tipo	Uso en el proyecto
Horas_Estudio_Semana	Continua	Variable explicativa principal y base de los términos polinómicos.
Puntaje_Examen	Continua	Variable objetivo de los modelos de regresión.
Aprobado	Binaria	Objetivo de clasificación: 1 si el puntaje es mayor o igual a 70; 0 en caso contrario.
Horas ² y Horas ³	Derivadas	Características usadas para explorar relaciones no lineales.

El control de calidad verificó 100 filas, ausencia de valores perdidos y puntajes dentro del rango de 0 a

100. La semilla 42 se mantiene en la división de datos y en la validación cruzada para

```
df = pd.read_csv("datos_estudiantes.csv")
df["Aprobado"] = (df["Puntaje_Examen"] >= 70).astype(int)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.30, random_state=42, stratify=y
```

que los resultados puedan reproducirse.

2. Procedimiento estadístico

2.1. Contraste de hipótesis

Se plantea un contraste bilateral sobre la pendiente poblacional de la regresión lineal:

$$H_0: \beta_1 = 0 \quad \text{frente a} \quad H_1: \beta_1 \neq 0$$

La estimación de la pendiente fue $\hat{\beta}_1 = 2.9923$, con un valor p de 2.45739×10^{-36} y un intervalo de confianza del 95 % entre 2.6951 y 3.2895. Como el valor p es menor que $\alpha = 0.05$, se rechaza la hipótesis nula. En la muestra, una hora semanal adicional se asocia con un aumento promedio cercano a tres puntos en el examen.

La correlación de Pearson fue $r = 0.8961$, lo que indica una asociación lineal positiva fuerte. Sin embargo, el diseño simulado y observacional impide concluir que aumentar las horas sea la causa directa del cambio en el puntaje.

2.2. Regresión y regularización

Se compararon tres especificaciones con la misma división de entrenamiento y prueba del 70/30. La regresión lineal simple sirve como referencia interpretable. La variante polinómica incorpora x , x^2 y x^3 . El modelo Ridge utiliza las mismas características y añade una penalización cuadrática:

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

La penalización reduce la magnitud de los coeficientes y ayuda a controlar la variabilidad de modelos con características correlacionadas. Se evaluó cada alternativa

mediante error cuadrático medio (MSE) y coeficiente de determinación (R^2) sobre el conjunto de prueba.

2.3. Regresión lógica

La probabilidad de aprobación se modela con la función logística:

$$P(Y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

probaron $C = 0.1, 1.0$ y 10.0 con los algoritmo de optimización (solver) liblinear y lbfgs. En scikit-learn, valores pequeños de C implican mayor regularización. Cada configuración se comparó con validación cruzada estratificada de cinco particiones y luego se evaluó en el conjunto de prueba.

```
for c in (0.1, 1.0, 10.0):  
    for solver in ("liblinear", "lbfgs"):  
        modelo = LogisticRegression(  
            C=c, solver=solver, max_iter=2000, random_state=42  
        )
```

3. Resultados y experimentos

3.1. Comparación de regresiones

Modelo	MSE	R ²	Interpretación
Lineal simple	21.330	0.749	Referencia de baja complejidad e interpretación directa.
Polinómico grado 3	19.930	0.766	Mejora el error al representar una curvatura moderada.
Ridge polinómico	19.597	0.770	Obtiene el mejor resultado y controla los coeficientes mediante penalización.

La regularización Ridge ofrece la mejor combinación de MSE y R²

en la partición utilizada. La mejora frente al modelo polinómico sin penalización es pequeña, por lo cual la conclusión prudente es que la regularización estabiliza la especificación más compleja, no que garantiza una superioridad general. La comparación debe repetirse con nuevas particiones y datos externos.

3.2. Experimentos de clasificación

C	Solver	Validación	Exactitud	Sens.	Espec.
0.1	liblinear	60.0 %	63.3 %	100.0 %	15.4 %
0.1	lbfgs	87.1 %	76.7 %	76.5 %	76.9 %
1.0	liblinear	81.4 %	73.3 %	94.1 %	46.2 %
1.0	lbfgs	85.7 %	76.7 %	76.5 %	76.9 %
10.0	liblinear	88.6 %	80.0 %	88.2 %	69.2 %
10.0	lbfgs	85.7 %	76.7 %	76.5 %	76.9 %

La configuración seleccionada fue C = 10.0 con liblinear, debido a que obtuvo la mayor exactitud media de validación cruzada, 88.6 %. En el conjunto de prueba alcanzó 80.0 % de exactitud, 88.2 % de sensibilidad y 69.2 % de especificidad. La matriz de confusión fue $\begin{bmatrix} 9 & 4 \\ 2 & 15 \end{bmatrix}$, siguiendo el orden verdadero negativo, falso positivo, falso negativo y verdadero positivo.

3.3. Interfaz desarrollada

La aplicación distribuye el análisis en cinco módulos: panorama, relación, clasificación, modelos y memoria técnica. Su estética de plano arquitectónico utiliza fondo azul real, cuadrícula

técnica, marcos rectangulares, líneas de dimensión, tipografía sans serif de alto contraste y etiquetas monoespaciadas. Esta dirección visual diferencia el proyecto de un tablero genérico y refuerza la idea de instrumento de medición.



1 Vista principal de la aplicación Dash con filtros, indicadores y distribuciones.

Los filtros de horas, puntaje y condición actualizan las tarjetas, histogramas, dispersión, pendiente y residuos. Un control independiente modifica el umbral de

```
@callback(  
    Output("kpi-total", "children"),  
    Output("grafico-dispersion", "figure"),  
    Input("filtro-horas", "value"),  
    Input("filtro-puntaje", "value"),  
    Input("filtro-condicion", "value"),  
)  
  
def actualizar_exploracion(rango_horas, rango_puntaje, condicion):  
    # Filtrado y reconstrucción de las salidas
```

clasificación. Finalmente, dos selectores permiten revisar de manera controlada las seis combinaciones de C y solver.

Conclusiones

El contraste de hipótesis confirmó una asociación estadísticamente significativa entre las horas de estudio y el puntaje del examen. La pendiente estimada indica un incremento promedio cercano a tres puntos por hora semanal adicional, y la correlación de 0.8961 respalda una relación positiva fuerte dentro de la muestra.

La comparación de regresiones mostró que el modelo Ridge polinómico obtuvo el menor error de prueba y el mayor R^2 , aunque la mejora frente a la regresión polinómica sin penalización fue moderada. Este resultado justifica conservar la regularización como mecanismo de control, sin afirmar una ventaja universal.

En clasificación, $C = 10.0$ y liblinear ofrecieron el mejor promedio de validación cruzada. El desempeño de prueba fue razonable, con mayor sensibilidad que especificidad. El control interactivo del umbral permite comunicar que estas métricas dependen de una decisión y no son propiedades invariables del modelo.

Glosario

- ***Binder* – entorno Binder reproducible:** Servicio que construye un entorno ejecutable en la nube a partir de un repositorio público y sus archivos de configuración.
- ***callback* – función reactiva:** Función que recibe cambios en los controles del dashboard y actualiza automáticamente sus salidas.
- ***MSE* – error cuadrático medio:** Promedio del cuadrado de las diferencias entre los valores observados y los valores predichos.
- **R^2 – coeficiente de determinación:** Proporción de la variabilidad de la respuesta explicada por el modelo de regresión.
- ***solver* – algoritmo de optimización:** Procedimiento numérico utilizado para estimar los coeficientes de la regresión logística.

referencias

- Plotly. (2026). *Dash Python User Guide*. <https://dash.plotly.com/>
- Binder Project. (2026). *Get started with Binder*.

<https://mybinder.readthedocs.io/en/latest/introduction.html>

- The Turing Way Community. (2021). *Zero-to-Binder*.

<https://the-turing-way.netlify.app/communication/binder/zero-to-binder.html>

- SciPy Community. (2026). *scipy.stats.linregress*. [Documentación oficial de SciPy](#)
- scikit-learn developers. (2026). *LinearRegression*. [Documentación oficial](#)
- scikit-learn developers. (2026). *LogisticRegression*. [Documentación oficial](#)
- McKinney, W. (2022). *Python for Data Analysis* (3.^a ed.). O'Reilly Media.